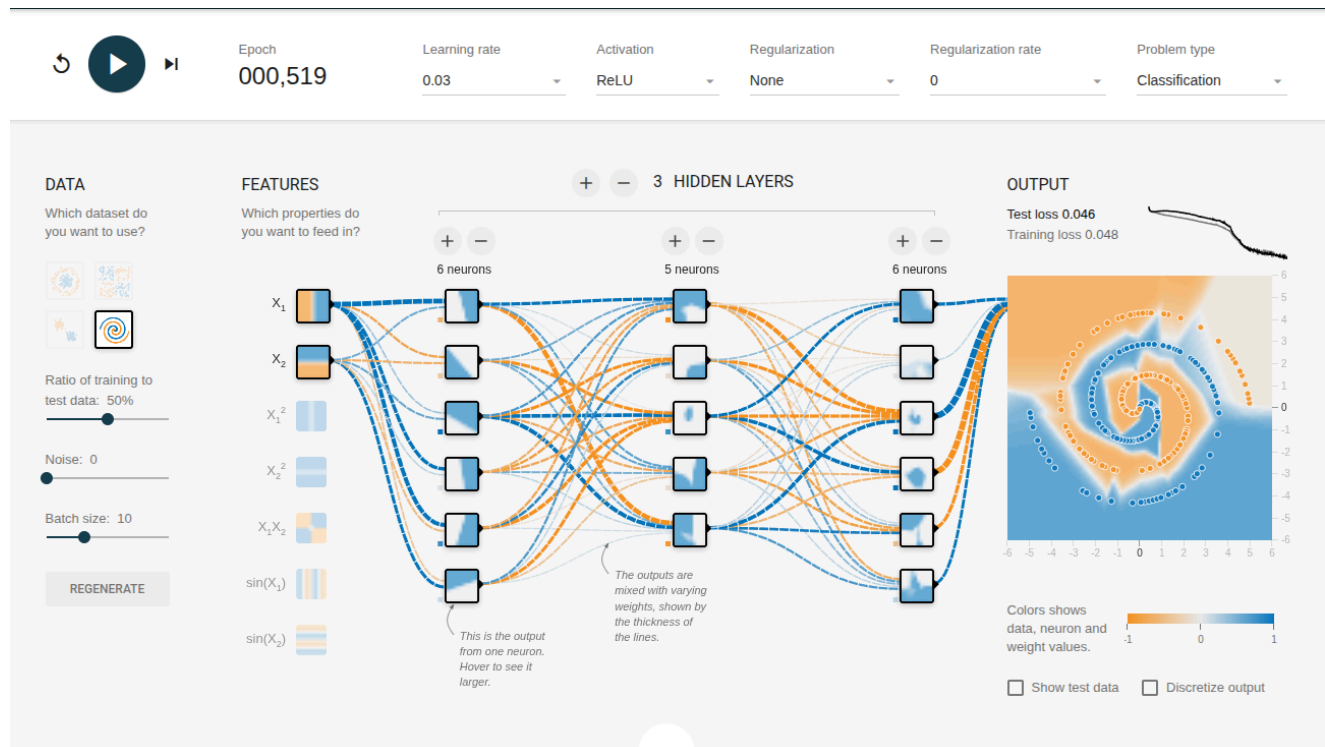


# Atividade Playground

Aluno: Erik Nathan

Email: [enob@cesar.school](mailto:enob@cesar.school)

Especialização Tech Leader 2025.01



## Análise de Simulação de Rede Neural para Classificação de Dados em Espiral

O objetivo deste estudo foi analisar o comportamento de uma rede neural na tarefa de classificação do dataset "espiral", disponível na plataforma TensorFlow Playground. Foram realizadas diversas simulações, ajustando hiperparâmetros como a função de ativação, a taxa de aprendizado (*learning rate*), a arquitetura da rede (número de camadas e neurônios) e a regularização.

### Configuração de Referência

Após testes iniciais, a função de ativação **ReLU** mostrou-se a mais adequada para este tipo de dado. A simulação destacada na imagem, que serviu como referência de um bom resultado, utilizou a seguinte configuração:

- **Taxa de Aprendizado:** 0.03
- **Função de Ativação:** ReLU

- **Regularização:** Nenhuma
- **Arquitetura:** 3 camadas ocultas com 6, 5 e 6 neurônios, respectivamente.

Com esta configuração, o modelo alcançou um **loss de teste de 0.046** e um loss de treino de 0.048 em **519 épocas**, demonstrando um excelente equilíbrio entre complexidade e eficiência.

## Análise dos Hiperparâmetros

A partir da configuração de referência, foram realizadas variações para entender o impacto de cada hiperparâmetro.

### 1. Influência da Arquitetura da Rede (Camadas e Neurônios)

Fixando a ativação ReLU e a taxa de aprendizado em 0.03, foram testadas diferentes arquiteturas, levando às seguintes conclusões:

- **Complexidade vs. Performance:** Nem sempre adicionar mais camadas e neurônios resulta em uma perda menor com menos épocas. O excesso de parâmetros pode, inclusive, gerar instabilidade e *overfitting*.
- **Estabilidade:** O aumento moderado no número de camadas pareceu contribuir para uma maior estabilidade no treinamento.
- **Instabilidade tardia:** Observou-se que, em algumas configurações, após atingir um valor mínimo, a perda voltava a aumentar e a oscilar.

A tabela abaixo compara alguns dos resultados obtidos:

Camadas Ocultas	Neurônios por Camada	Loss Mínimo	Épocas	Observação
3	6, 5, 6	0.046	519	<b>Modelo da imagem. Ótimo balanço.</b>
4	6, 5, 5, 6	0.091	473	Pior resultado com mais complexidade.
4	6, 4, 4, 6	0.098	559	Pior resultado com mais complexidade.
4	8, 6, 6, 8	0.016	371	Menor perda obtida, porém com custo de maior complexidade (risco de overfitting).

### 2. Influência da Taxa de Aprendizado (Learning Rate)

- **Taxas de aprendizado baixas** resultaram em uma convergência mais lenta, exigindo um número maior de épocas para ajustar os pesos da rede.

- **Aumentar a taxa de aprendizado não garantiu melhora.** Em testes com *learning rate* de 0.1, os resultados não superaram a configuração de referência. Por exemplo, para o mesmo modelo da imagem, foram necessárias 514 épocas para atingir uma perda de 0.052, um resultado inferior.

## Por fim

A simulação evidenciou que encontrar uma boa configuração para uma rede neural é um processo empírico de busca por equilíbrio. A arquitetura de 3 camadas com 6, 5 e 6 neurônios, combinada a uma taxa de aprendizado de 0.03 e ativação ReLU, provou ser a mais eficiente para o problema, oferecendo a menor perda com a menor complexidade computacional.